FIT5230 Milestone 3 交接说明（第二版）

Dark.MODELBREAKERS · 2026 年 10 月 18 日 11:20 · 写给队友

这份替代 10 月 17 日那版。增加了周六夜里到周日上午的四批实验结果、PreDecodeGuard 的最新进展，以及还没做的事。M3 截止 10 月 22 日 23:55。仓库 github.com/CAVOK1407/FIT5230-Ass1，本地 ~/Documents/ChatGPT/FIT5230/github/FIT5230-Ass1。

1. 现在的状态

评分项	分值	状态
框架进展与成果	5（组）	技术实验全部做完，六份结果文档，可以直接写幻灯片
同伴互动	3（组）	PreDecodeGuard 已互动两轮并收到材料包；另两队未回复
个人策略 ×2	11（每人）	策略 B 材料已到但有一处需要全队决定（见第 4 节）；第二人的策略未定
汇报质量	1（组）	幻灯片未做
Colab 笔记本	5（组）	未开始

一句话：技术这头做完了，剩下的全是人和交付物——回帖、Gradio、笔记本、幻灯片、分工。

2. 周六那版之后新增的实验

四批，全部 SD 1.5 的 100 张，评测口径不变（从存盘 PNG 重算）。

2.1 T2 封顶变体（修过冲）

做法：自写 PGD，步长 ε/10，代理分数一到真实开发集图片分数的中位数就停，跨过上限那一步用二分法缩短，让分数正好落在上限。上限：代理 E 单独 12.3，集成 9.2。

配置	E	R	D	S	AUC E / R / D / S	PSNR	LPIPS
A5 官方	1.00	0.77	0.39	0.90	0.00 / 0.84 / 0.96 / 0.99	34.0	0.126
ENS 集成	1.00	1.00	1.00	0.97	0.01 / 0.00 / 0.15 / 0.98	33.9	0.126
CAPB_E 封顶	1.00	0.13	0.01	0.31	0.34 / 0.99 / 1.00 / 1.00	38.3	0.009
CAPB_ENS 封顶	1.00	1.00	0.60	0.38	0.45 / 0.51 / 0.84 / 1.00	38.1	0.009

结果：集成版把 E 的 AUC 从 0.00 拉到 0.45、R 从 0.00 到 0.51——这两个检测器上攻击图和真照片已经分不开，调阈值也抓不到。这是对 M2 第 8 节那条结论的正面回答。

代价：扰动小到 LPIPS 0.009，没进损失的 S 从 0.97 掉到 0.38，JPEG 75 之后 E 只剩 0.22。另外存盘图的分数仍比上限高（16.3 对 9.2），因为解码路径把分数放大了近一倍——要在解码后的图上封顶才能解决，没做。

2.2 T3 期望变换（修压缩鲁棒性）

做法：PGD 每一步的损失在三个视图上平均——原图、JPEG 75、0.5 倍缩放再放回。前向真做变换，反向当恒等。

条件	ENS	EOT_ENS	说明
无损 PNG	0.99	0.99	不掉

JPEG 95	0.92	0.96	
JPEG 75	0.42	0.65	D 从 0.06 到 0.54，R 从 0.62 到 0.88
JPEG 50	0.23	0.38	
缩放 0.5	—	—	检测器自己把 96% 真照片判成 AI，无法评估

画质只差 0.7 dB，每张多 4.6 秒。M2 测出的 JPEG 洞补上一大半。

2.3 夜间批次：三个核对

问题	做法	结果
假设一只在代理 E 上成立吗	用集成重跑 A2、X2、X4	一致：去掉潜空间优化 1/400，换干净控制图 280/400
那些 1–4/400 是噪声吗	换种子（42→43）跑 A5 和 ENS	逐像素相同，0/400。噪声底是 0
期望变换放进潜空间优化呢	ENS 加 --lao_eot both	0/400，什么都不改

第三条是先预测再验证的：我们先按假设一预测放进潜空间优化应该无效，再跑，结果正是 0/400。汇报时这条最有分量——它把假设一从事后解释变成了能预测新结果的东西。

2.4 合起来的结论

不过冲、能迁移、扛压缩，三个目标目前任何一个版本只能占两个：集成占能迁移，封顶占不过冲，期望变换占扛压缩。防守方同时用双侧检验加检测前压一次 JPEG，三个版本都挡得住——这正好是 M4 角色反转要的东西。

3. 技术部分完整清单

编号	内容	状态
T1	零迭代对照等 5 个配置（SD 2.1，20 张）+ PGD 一致性检查	完成
T4	9 个配置 + 6 种后处理（SD 1.5，100 张）	完成
T5	像素 PGD 基线 8/255	完成
T2 / T2b	封顶变体（早停版 + 二分版），各两个代理	完成
T3	期望变换放进 PGD，两个代理	完成
夜间	集成版假设一、换种子、期望变换放错位置	完成
T6	外部检测器 UnivFD（可选）	未做，留给论文
T7	扫起始步	取消：数据已证明在任何解码路径上都到不了输出

4. PreDecodeGuard-SD3.5（策略 B）——需要全队决定

进展：我们提议做潜空间访问攻击，对方同意开一条独立试点，10 月 18 日上午发来材料包，已下载到 ~/Documents/ChatGPT/FIT5230/predecodeguard/。

包里有：10 个 float16 潜变量（1×16×128×128）、冻结的 CNN 权重和前向代码、预处理方式、阈值 0.6528、每个文件的 SHA-256、基线分数、评分和校验脚本、解码器信息。扰动预算是 L∞ ≤ 0.1（原始潜变量单位），对方要求我们开跑前先确认。

需要决定的事：这十个潜变量解码出来是血腥伤害的图像（对方 README 明确写明），试点要做的是扰动它们，使暴力内容仍然可见、但安全检测器判为无害。产物就是十个能绕过这个安全检测器的文件。做不做、谁来做，要全队和导师确认，不要默认往下走。

不做绕过那一轨的情况下，同一批材料仍然能做出有分量的东西：

- 跑分分析：十个样本的基线分数全是 0.98 到 0.99999，这正是我们 M2 在检测器 E 上发现的过冲模式。用我们自己的发现去分析他们的检测器。
- 不往有害方向测鲁棒性：在同样预算内往更可疑的方向扰动、或加随机噪声，测分数能移动多少，刻画决策边界。
- 用 T4 的结果给他们的前提定界：同一个潜变量两种解码方式会得到不同判决，这是对潜变量能预测解码后内容这一前提的定量约束，数字现成。
- 把这个判断本身写进汇报：批判性分析与影响占 11 分里的 5 分，讲清楚限度和取舍比讲成功更有料。

无论走哪条路，都要尽快回 Osama 一句话，他在等我们确认预算。

5. 另外两支队

队伍	状态	怎么办
Light.Umbrella（DAA-Lite）	已发出，未回复	再催一次；没回就按发了什么、预期什么、没回说明什么来讲
Light.Fahhh（SafeDecoding）	回帖可能没发；未回复	他们有公开 Gradio 页面，不用等回复，自己跑 13 个提示词和 4 组对照，约一小时。第二个人的策略 C 就靠这个

6. 还没做的事（按紧急程度）

事	分	估时	谁
回 Osama，确认走哪条路	策略 B 的前提	10 分钟	待定
在 Fahhh 的 Gradio 上跑 13 个提示词 + 4 组对照	策略 C 的全部材料	1 小时	第二人
定分工：谁讲哪个策略	11 × 2	现在	两人
Colab 笔记本：加 T1–T5 配置，从头跑一遍留输出	5	半天	一人
幻灯片 12–14 页 + 排练两遍卡表	1 + 全部	半天	两人
三支队互动汇总成一页表	3	1 小时	待定
确认辅导课是周几几点	影响所有截止时间	—	待定

Colab 笔记本的要求（评分表写明的）：所有代码单元格带已渲染输出；路径集中在开头一个变量里（现在代码里有 16 处写死的 /content/drive）；不改官方文件（M2 笔记本改了 6 个官方文件里的

8 行，要换成补丁或包装的写法）；文字单元格写明 dev/test 划分，以及条件成功率只数攻击前被抓住的图（防数据泄漏那 1 分）。

7. 文件在哪

文件	内容
docs/M3 交接说明_2026-10-18.docx	本文件
docs/M3_T1_RESULTS_ZH.md	T1（SD 2.1，20 张）
docs/M3_T4_RESULTS_ZH.md	T4（SD 1.5，100 张）+ 第 8 节夜间补充
docs/M3_T2_T3_RESULTS_ZH.md	T2 封顶、T2b 二分、T3 期望变换
docs/M3_M4_RESERVE_ZH.md	M3/M4 保留项（M2 时写的）
docs/ M3_FOLLOWUP_MESSAGES_EN.md	给三支队的催帖和记录表
paper_frozen/	论文第 6、7 节冻结快照和哈希，标签 m3-hypotheses-frozen
StealthDiffusion/results/m3_sd15/	15 个配置的记录和评测汇总
predecodeguard/	PreDecodeGuard 的材料包

8. 常用命令

cd ~/Documents/ChatGPT/FIT5230/github/FIT5230-Ass1/StealthDiffusion && conda activate fit5230m2

bash m3_run.sh status　　查看每个配置跑了几张

bash m3_run.sh eval15　　重新评测全部配置

python m3_report.py --runs 名=目录 ... --pairs A:B　　配置两两对比

提交：git add -A，然后 git commit，然后 git push。results/ 下的 PNG、data15/、日志不进仓库，记录和评测 CSV 进。